

Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и кибербезопасности
Высшая школа технологий искусственного интеллекта

ОТЧЁТ О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

по теме:

Автоматизированная система предиктивной аналитики

Исследование временной допустимости внешних табличных признаков

Выполнила

студентка гр. 5140201/50302

Р. В. Попова

Руководитель

старший преподаватель ВШТИИ, к. ф.-м. н.

А. В. Константинов

«___» _____ 2026 г.

Санкт-Петербург

2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Постановка задачи и назначение стенда	4
2 Методика и реализация	5
3 Результаты и их интерпретация	7
ЗАКЛЮЧЕНИЕ	13
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	14

ВВЕДЕНИЕ

Автоматизированная предиктивная аналитика предполагает подготовку данных, построение признаков и обучение модели. При подключении внешних таблиц возникает дополнительная задача: установить, могло ли значение быть известно в момент прогноза. Дата события не всегда совпадает с датой публикации. Поздняя запись или исправленная версия могут создавать утечку даже при хронологическом разделении обучения и теста.

Официальная тема НИР – «Автоматизированная система предиктивной аналитики». В рамках летней практики исследуется допуск внешних табличных значений при неполной информации о времени их доступности. Цель практики – реализовать воспроизводимый прототип временного контракта и оценить, как потеря точных дат влияет на покрытие и качество прогнозирования.

Поиск полезных внешних данных уже автоматизируется, например, в Kitana [3]. Featuretools позволяет задавать временное отсечение и вторичный индекс для столбцов, становящихся известными позже [4]. Проверка доступности при известных датах также применяется в системах хранения признаков [1, 2]. Поэтому самостоятельным новым результатом не считается само сравнение временных меток.

Исследовательский вопрос работы: позволяют ли корректные интервалы доступности сохранять больше полезных значений, чем использование только точных дат, без увеличения числа поздних допусков? Для ответа разработан стенд с контролируемой потерей метаданных. Практический результат – код контракта, сравнение четырёх политик и анализ всех 27 сценариев, формирующие основу дальнейшего исследования на реальных источниках.

1 Постановка задачи и назначение стенда

Для внешнего значения различаются время события e , момент прогноза t и время доступности конкретной версии a . Требуется допускать значение только при подтверждении $a \leq t$. Если точная дата неизвестна, используются нижняя и верхняя границы $[l, u]$. Они должны описывать именно доступность значения, а не период, к которому относится событие.

Например, событие произошло 1 марта, а публикация состоялась между 3 и 7 марта. Для прогноза 5 марта дата события проходит отсечение, но интервал публикации не позволяет доказать доступность. Система должна сохранить неопределённость, а не объявлять значение безопасным по умолчанию.

Проверяемая гипотеза состоит в том, что интервальное свидетельство позволяет сохранить часть значений со скрытой точной датой. Ожидаемый эффект зависит от ширины интервала относительно момента прогноза. При полных датах преимущества быть не должно; при слишком поздней публикации безопасный допуск невозможен.

Стенд выполняет три функции:

1. задаёт истинные даты и независимо ухудшает доступные системе метаданные;
2. сравнивает покрытие, ошибочный допуск и качество на одинаковых тестовых объектах;
3. сохраняет исходные сведения и прогнозы для независимого пересчёта.

2 Методика и реализация

2.1 Контракт и политики сравнения

При наличии непротиворечивого свидетельства правило имеет вид:

$$D(x, t) = \begin{cases} \text{Accept}, & u \leq t, \\ \text{Reject}, & l > t, \\ \text{Unknown}, & l \leq t < u. \end{cases}$$

Отсутствующие границы, обратный интервал или отсутствие идентификатора свидетельства также дают Unknown. Если интервал действительно содержит a , то из $u \leq t$ следует $a \leq t$. Гарантия условна: неверные границы могут привести к неверному допуску.

Сравниваются четыре политики: event-only проверяет время события, exact-only использует только точные даты, interval применяет контракт, ogacle знает истинные даты. Oracle – эталон доступности, а не оптимальности модели; его AUC на конечном тесте не обязательно максимален.

Unknown создаёт пропуск значения, сохраняя объект. Медианы и индикаторы пропусков определяются на обучении; пустые столбцы исключаются. Модель – логистическая регрессия без настройки по тесту, предел 1000 итераций.

2.2 Данные и временное разбиение

В каждом из 10 повторов 1000 объектов. Цель зависит от латентного фактора. Базовый признак зашумлён, два внешних содержат более точный сигнал. Третий – намеренно поздний прокси цели для диагностики утечки.

Событие предшествует прогнозу на пять дней. Для двух сигнальных внешних признаков дата доступности равна дате события плюс задержка 1, 4 или 8 дней и случайная добавка от 0 до 1 дня. Поздний прокси всегда становится доступен после прогноза. Обучение содержит 693 объекта, тест – последние 300; между ними исключены семь объектов для созревания меток. Разбиение одинаково для всех политик.

2.3 Потеря метаданных и метрики

Точная дата скрывается с вероятностью 0, 0,5 или 1 независимо от метки. Взамен выдаётся содержащая её календарная корзина шириной 1, 4 или 8 дней. Для всех политик используются одинаковые данные и маски. Комбинация трёх задержек, трёх долей скрытия и трёх ширин даёт 27 сценариев. С учётом 10 seed и четырёх политик выполнено 1080 обучений.

Покрытие – доля принятых внешних ячеек теста, риск – доля поздних среди принятых. При нулевом допуске риск не определён. Сохраняются доля Unknown, ROC-AUC, log-loss и время обучения с прогнозом, без стоимости временной проверки.

Основной сценарий задан до запуска: задержка 1 день, 50% скрытых дат и ширина 4 дня. Для разности AUC применяется парный bootstrap по 10 seed, 10000 повторных выборок. Остальные сценарии служат анализом чувствительности, без отдельных заявлений о статистической значимости каждого сравнения.

Отдельный скрипт проверяет решения по сохранённым истинным датам, метрики по прогнозам и контрольные суммы. Графики строятся из результатов без повторного обучения.

3 Результаты и их интерпретация

3.1 Основное сравнение

В основном сценарии интервальный контракт сохраняет все доступные сигнальные значения, поэтому совпадает с oracle. Exact-only теряет примерно половину этих значений из-за скрывания точных дат. Средние по 10 seed приведены в таблице 3.1.

Таблица 3.1 — Основной сценарий: задержка 1 день, скрыто 50% дат, интервал 4 дня

Политика	ROC-AUC	Покрытие	Поздних среди принятых
Event-only	1,0000	100,00%	33,33%
Exact-only	0,7584	33,08%	0%
Interval	0,8148	66,67%	0%
Oracle	0,8148	66,67%	0%

Прирост AUC равен 0,0565, bootstrap-интервал 95% составляет [0,0479; 0,0686]. Интервал характеризует вариацию синтетических повторов, а не переносимость на реальные домены. Доля Unknown для interval равна 12,86% внешних ячеек. Поздний прокси обеспечивает event-only AUC 1,0, поэтому его результат демонстрирует завышение оценки, а не полезность допустимого прогноза.

3.2 Покрытие во всех сценариях

На рисунке 3.1 показаны все 27 сценариев. Строки соответствуют задержке публикации, столбцы – ширине интервала, точки – доле скрытых точных дат. На каждом графике одинаковые шкалы. Совпавшие линии означают одинаковое покрытие, а не отсутствие данных.




Рисунок 3.1 — Покрытие при разных задержках, ширинах интервала и долях скрытых дат. Средние по 10 seed

При нулевой потере дат exact-only, interval и oracle совпадают. При скрывании дат exact-only теряет доступные значения. Интервальная политика сохраняет часть из них, если верхняя граница укладывается в момент прогноза. Широкие интервалы чаще пересекают этот момент и уменьшают преимущество.

Задержка 8 дней делает оба сигнальных внешних признака недоступными, поскольку событие произошло лишь за пять дней до прогноза. Поэтому покрытие всех трёх корректных политик равно нулю. Они продолжают строить прогноз по базовому признаку. Принимать больше значений в таком сценарии означало бы допускать поздние данные.

3.3 Качество и величина эффекта

Рисунок 3.2 показывает абсолютный AUC на тех же объектах теста. Event-only исключён из этой визуализации как заведомо протекающий контроль; его результат приведён отдельно в таблице. Все панели используют единую вертикальную шкалу.




Рисунок 3.2 — Абсолютный ROC-AUC по всем сценариям. Средние по 10 seed

Падение покрытия часто сопровождается потерей предиктивного качества, поскольку модель получает меньше внешнего сигнала. Однако покрытие и AUC не эквивалентны: полезность сохранённых значений и особенности обученной модели также влияют на результат. Сравнение выполнено на одном тесте, без исключения трудных объектов.

Для точного сопоставления на рисунке 3.3 приведена средняя парная разность AUC interval минус exact-only. Нулевые значения показы-

вают режимы, в которых метод не даёт выигрыша. Сценарии без скрывания дат проверяют согласованность политик, а задержка 8 дней задаёт границу применимости.




Рисунок 3.3 — Разность ROC-AUC interval минус exact-only. Каждая ячейка соответствует одному из 27 сценариев

Например, при задержке 4 дня, скрывании 50% дат и интервале 8 дней средний прирост составляет лишь 0,0065. Разность по отдельным seed меняется от $-0,0045$ до $0,0188$: улучшение не наблюдается в каждом повторе. При задержке 8 дней корректные политики совпадают с AUC 0,6496, используя только базовый признак.

3.4 Неопределённость и дополнительные проверки

Доля Unknown показана на рисунке 3.4. Для exact-only это доля значений без точной даты; для interval — доля интервалов, пересекающих момент прогноза. Поэтому это сравнение последствий двух правил обработки метаданных, а не качества классификации одного и того же отрицательного класса. Oracle имеет полные даты и не возвращает Unknown.




Рисунок 3.4 — Доля неопределённых внешних ячеек по всем сценариям

Рост Unknown объясняет, почему широкие интервалы могут быть недостаточны даже при истинных границах. На всех 27 сценариях число поздних допусков `interval` равно нулю. Этот результат согласуется с условием $a \in [l, u]$ и сам по себе не доказывает правильность свидетельств реального источника.

Ранее выполненные эксперименты дополняют проверку. На пяти seed сквозного синтетического конвейера AUC составил 0,8433 против 0,7033 для `exact-only`; этот станд отличается от нового генератора и напрямую с ним не усредняется. На десяти парах Valentine F1 составил 0,6399 против 0,6072 у сопоставления по именам, но интервал разности $[-0,0730; 0,1265]$ включает ноль. На NYC 311 AUC равен 0,9514 при предположении доступности полей регистрации; утёкший контроль даёт 0,99996. Эти результаты не заменяют валидацию дат публикации.

3.5 Ограничения и дальнейшая работа

Исследование использует искусственные данные и календарные интервалы, гарантированно содержащие истину. Скрытие независимо от метки; зависимое скрытие и ошибочные свидетельства не исследованы. Поздний прокси намеренно усилен, поэтому AUC event-only не отражает типичный масштаб утечки в реальном источнике.

Реальные проверки ограничены: NYC содержит первые строки месяцев, а доступность части полей предполагается; Valentine проверяет сопоставление схем. Текстовый benchmark содержит повторяющиеся описания и не доказывает переносимость. Следующий этап – собрать независимые даты публикаций, проверить неверные границы и зависимую потерю метаданных, затем включить контракт в поиск внешних источников. До этого результат рассматривается как стенд и прототип этапа практики.

ЗАКЛЮЧЕНИЕ

В ходе практики реализован прототип контроля доступности внешних табличных значений в автоматизированной системе предиктивной аналитики. Контракт различает подтверждённый допуск, отказ и неопределённость. Подготовлен воспроизводимый стенд с 27 сценариями потери временных метаданных и четырьмя политиками, выполнено 1080 обучений.

В основном сценарии интервальный метод увеличил покрытие с 33,08% до 66,67%, а ROC-AUC с 0,7584 до 0,8148 без поздних допусков. Анализ всех сценариев показывает границы эффекта: при известных точных датах преимущество отсутствует, широкие интервалы уменьшают полезный допуск, а поздняя публикация не позволяет использовать внешние значения ни одной корректной политике.

Полученный результат поддерживает гипотезу о пользе частичных временных свидетельств на контролируемом стенде. Он не устанавливает универсальное превосходство алгоритма или автоматическое восстановление дат. Практический итог – протокол сравнения и программный компонент для дальнейшего исследования на независимых реальных источниках.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Microsoft. Offline feature retrieval using a point-in-time join. 2026. URL: <https://learn.microsoft.com/azure/machine-learning/offline-retrieval-point-in-time-join-concepts>.
- [2] Feast. Point-in-time joins. URL: <https://docs.feast.dev/getting-started/concepts/point-in-time-joins>.
- [3] Huang Z., Subramaniam P., Castro Fernandez R., Wu E. Kitana: Efficient Data Augmentation Search for AutoML. 2023. <https://arxiv.org/abs/2305.10419>.
- [4] Featuretools. Handling Time. Документация версии 0.19.0. https://docs.featuretools.com/en/v0.19.0/automated_feature_engineering/handling_time.html. Дата обращения: 10.09.2026.
- [5] NYC Open Data. 311 Service Requests from 2020 to Present. URL: <https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2020-to-Present/erm2-nwe9>.