

Санкт-Петербургский политехнический университет Петра Великого
Институт компьютерных наук и кибербезопасности
Высшая школа технологий искусственного интеллекта

ОТЧЁТ О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

по теме:

Автоматизированная система предиктивной аналитики

Исследование временной допустимости внешних табличных признаков

Выполнила

студентка гр. 5140201/50302

Р. В. Попова

Руководитель

старший преподаватель ВШТИИ, к. ф.-м. н.

А. В. Константинов

«___» _____ 2026 г.

Санкт-Петербург

2026

АННОТАЦИЯ

Работа посвящена автоматизированному контролю временной допустимости внешних табличных признаков в предиктивной аналитике. Для прогноза важно различать дату события и момент, когда значение стало доступно обучающей системе. Их смешение создаёт временную утечку и завышает оценку качества.

Цель работы – реализовать воспроизводимый прототип временного контракта, который разделяет решения *Accept*, *Reject* и *Unknown*, сохраняет причины отказа и допускает только значения, опубликованные к моменту прогноза. Протокол проверен на синтетическом benchmark v4, сквозном синтетическом конвейере, десяти парах Valentine и временной выборке NYC 311.

Положительный результат ограничен контролируемыми условиями. Интервальный контракт повысил средний ROC-AUC с 0,7033 до 0,8433 относительно точных меток при отсутствии поздних и недоказанных допусков. Универсальное превосходство над существующими методами и автоматическое доказательство доступности неизвестного источника не установлены.

Ключевые слова: предиктивная аналитика, временная утечка, доступность признаков, point-in-time join, историческое соединение, воспроизводимость.

Содержание

АННОТАЦИЯ	2
1 Проблема и цель исследования	4
1.1 Проблема	4
1.2 Цель и задачи	4
1.3 Краткий контекст и граница новизны	5
2 Метод и программная реализация	6
2.1 Временной контракт	6
2.2 Компоненты прототипа	6
3 Экспериментальный протокол	8
3.1 Наборы и разбиения	8
3.2 Метрики и воспроизводимость	8
4 Результаты	10
4.1 Benchmark v4	10
4.2 Сквозной временной pipeline	10
4.3 Сопоставление схем и NYC 311	11
5 Обсуждение и ограничения	12
5.1 Что подтверждено	12
5.2 Что не подтверждено	12
5.3 Соответствие заданию	12
ЗАКЛЮЧЕНИЕ	13

1 Проблема и цель исследования

1.1 Проблема

В табличных системах одна строка может содержать дату события, дату публикации, дату исправления и дату фактической доступности. Для прогноза на момент t значение допустимо только при наличии подтверждения $a \leq t$. Простая проверка даты события этого не гарантирует: запись могла появиться позже или быть исправлена задним числом.

Если позднее значение попадает в обучение, модель получает информацию из будущего. Метрика на тесте растёт, но результат нельзя воспроизвести в момент принятия решения. Поэтому основным объектом работы является не отдельный классификатор, а исполняемый контракт допуска внешних признаков.

1.2 Цель и задачи

Цель – разработать и проверить компактный прототип временной верификации для автоматизированной системы предиктивной аналитики.

Для достижения цели решены следующие задачи:

1. формализованы даты события, прогноза и публикации;
2. реализованы состояния *Accept*, *Reject* и *Unknown*;
3. сформирован benchmark v4 с независимыми baseline и явным учётом покрытия;
4. проведён временной эксперимент с семидневным созревaniem меток;
5. проверены переносимые части решения на реальных табличных парах и NYC 311;

6. сохранены код, данные, конфигурации, прогнозы, логи и контрольные суммы.

1.3 Краткий контекст и граница новизны

Point-in-time joins и задержка появления источника уже описаны в инженерных системах работы с признаками. Сопоставление таблиц и временная валидация также имеют опубликованные benchmark-решения. Поэтому работа не заявляет новый универсальный алгоритм. Её проверяемый вклад – связка строгого временного контракта, явного *Unknown*, журнала причин и воспроизводимого сравнения, пригодная для дальнейшего расширения на автоматическое получение свидетельств доступности.

2 Метод и программная реализация

2.1 Временной контракт

Для значения x хранятся дата события e , дата прогноза t и интервал публикации $[a_{min}, a_{max}]$. Правило допуска имеет вид:

$$D(x, t) = \begin{cases} A, & a_{max} \leq t, \\ R, & a_{min} > t, \\ U, & \text{иначе.} \end{cases}$$

Здесь A означает *Accept*, R – *Reject*, а U – *Unknown*. Для составного кандидата действует консервативное правило: одна недопустимая ячейка отклоняет весь кандидат. Неизвестные строки не превращаются в отрицательные или положительные примеры, а учитываются отдельно через покрытие и риск принятия.

2.2 Компоненты прототипа

Реализация состоит из четырёх связанных частей:

- `src/temporal.py` – интервальная проверка, версии и причины решений;
- `src/benchmark.py` – `benchmark v4` и сравнение `baseline`;
- `src/pipeline.py` – сквозной синтетический конвейер с временным разрывом;
- `src/matching.py` и `src/nyc.py` – пилот сопоставления схем и временная оценка NYC 311.

Архитектура конвейера показана на рисунке 2.1. Важное ограничение: интервалы публикации в синтетическом эксперименте задаются генератором.

Система проверяет контракт, но не извлекает достоверные интервалы из произвольного неизвестного сайта.




Рис. 2.1 — Последовательность обработки внешнего признака

3 Экспериментальный протокол

3.1 Наборы и разбиения

Проверены четыре уровня.

1. Benchmark v4: 80 задач, из них 40 train, 16 dev и 24 test; на тесте 576 кандидатов.
2. Сквозной синтетический pipeline: пять seed, 1500 сущностей на seed, горизонт семь дней, временной purge семь дней.
3. Valentine: десять реальных пар таблиц с опубликованной разметкой соответствий.
4. NYC 311: первые 2000 строк каждого месяца 2023 года, всего 24000 строк до очистки; тестовые месяцы – август–декабрь.

В NYC 31 строка исключена из-за некорректной даты, 569 строк без разрешённой категории сохранены как неопределённые. Обучающие метки для каждого временного блока созревают строго до начала теста. Признак длительности в отрицательном контроле задан намеренно и показывает эффект временной утечки.

3.2 Метрики и воспроизводимость

Для benchmark приведены полные F1, условный F1 на решённых строках, покрытие и риск среди принятых. Для pipeline и NYC используются ROC-AUC, macro-F1 и log-loss. Для Valentine приведены precision, recall, F1 и top-1 recall; парная bootstrap-оценка строится по десяти парам.

Полный запуск выполняется командой `python run_all.py`. Он запускает 22 теста и четыре эксперимента, записывает CSV с прогнозами и разбиениями, конфигурации и логи. Скрипт `verify_results.py` независимо пе-

решчитывает метрики из сохранённых файлов и сверяет 2129 контрольных сумм входов и кода.

4 Результаты

4.1 Benchmark v4

В протоколе лучший гибридный порог выбран на dev: 0,525; метрики рассчитаны с учётом покрытия и состояния Unknown.

Таблица 4.1 — Результаты классификации временной допустимости

Метод	Покрытие	F1 полный	F1 решённые	Принятые invalid
Явная метка	0,3333	0,5000	1,0000	0
Время события	1,0000	0,5000	0,5000	192
Только текст	1,0000	0,6094	0,6094	139
Гибрид (dev)	0,9097	0,8099	0,8503	50
Гибрид (0,625)	0,6701	0,8008	0,9974	0

Гибрид достигает полного F1 0,8099 при покрытии 0,9097 и принимает 50 недопустимых кандидатов. При этом 573 из 576 тестовых описаний встречаются в train, поэтому перенос на новые источники не доказан.

4.2 Сквозной временной pipeline

На рисунке 4.1 видно, что использование только даты события даёт утечку. Интервальный контракт сохраняет полезные значения, но запрещает поздние и недоказанные ячейки.




Рис. 4.1 — Сравнение политик на пяти синтетических seed

Таблица 4.2 — Сквозные результаты временного контроля

Политика	ROC-AUC	SD	Поздние ячейки	Недоказанные допуски
Время события	1,0000	0,0000	15000	7500
Точные метки	0,7033	0,0327	0	0
Интервальный контракт	0,8433	0,0347	0	0

Средний прирост interval contract относительно exact-only составил 0,1400; bootstrap 95% CI: [0,1331; 0,1478]. Это подтверждает механизм на контролируемом стенде, но не доказывает качество автоматического извлечения метаданных.

4.3 Сопоставление схем и NYC 311

Для Valentine многосигнальный baseline получил средний F1 0,6399 против 0,6072 для сопоставления только по именам. Bootstrap-интервал разности $[-0,0730; 0,1265]$ включает ноль, поэтому статистически устойчивое превосходство не заявляется.

Для NYC средний ROC-AUC при допущении доступности полей регистрации равен 0,9514, macro-F1 – 0,8231. Отрицательный контроль с утёкшей длительностью дал ROC-AUC 0,99996. Разрыв показывает, почему временная доступность должна быть частью протокола. Срез первых 2000 строк месяца не является репрезентативной оценкой города.




Рис. 4.2 — Временные блоки NYC 311 и отрицательный контроль

5 Обсуждение и ограничения

5.1 Что подтверждено

Подтверждены три практических свойства прототипа: поздние значения не проходят строгий интервальный контракт; неизвестность не маскируется под отрицательный класс; временные разбиения, прогнозы и причины решений сохраняются для повторной проверки. Это делает оценку более честной, чем условное сравнение только по решённым строкам.

5.2 Что не подтверждено

Работа не доказывает универсальное превосходство TAVA, новую модель машинного обучения или промышленную готовность. Синтетические интервалы известны генератору. В NYC доступность полей регистрации предполагается, а выборка ограничена первыми строками месяцев. В benchmark есть повторяющиеся шаблоны train/test. Valentine используется как прозрачный локальный baseline, а не как заявление о SOTA.

5.3 Соответствие заданию

Результат соответствует исследовательскому треку практики: сформулирована проверяемая проблема, реализован прототип, проведены baseline-сравнения, сохранены код и данные, выполнена временная валидация и подготовлен воспроизводимый запуск. Полная выпускная квалификационная работа в объём практики не включается.

ЗАКЛЮЧЕНИЕ

Разработан и проверен компактный прототип автоматизированной системы предиктивной аналитики с явным контролем времени доступности внешних признаков. Benchmark v4, синтетический pipeline, Valentine и NYC 311 собраны в единый воспроизводимый пакет.

Основной результат – интервальный контракт: на контролируемом синтетическом стенде он дал средний ROC-AUC 0,8433 против 0,7033 у exact-only и не допустил поздних или недоказанных значений. Остальные эксперименты уточняют границы применимости: эффект сопоставления схем статистически неустойчив, NYC не репрезентативен, а универсальная научная новизна не установлена.

Следующий исследовательский шаг – автоматически получать независимые свидетельства дат публикации и проверять их качество на новых доменах. До этого результат следует рассматривать как воспроизводимый протокол и инженерный прототип, а не как готовую универсальную систему.

Литература

- [1] Microsoft. Offline feature retrieval using a point-in-time join. 2026. URL: <https://learn.microsoft.com/azure/machine-learning/offline-retrieval-point-in-time-join-concepts>.
- [2] Feast. Point-in-time joins. URL: <https://docs.feast.dev/getting-started/concepts/point-in-time-joins>.
- [3] Arjovsky A. et al. Towards Causal Representation Learning. 2020. URL: <https://arxiv.org/abs/2003.09758>.
- [4] Nargesian F. et al. METAM: A Metadata-Augmented Table Matching Benchmark. 2023. URL: <https://arxiv.org/abs/2304.09068>.
- [5] Santos A. et al. Retrieve, Merge, Predict: Augmenting Tables with Data Lakes. 2024. URL: <https://arxiv.org/abs/2402.06282>.
- [6] Nargesian F. et al. Table Union Search. 2020. URL: <https://arxiv.org/abs/2010.07386>.
- [7] DATALORE: Data Lake Table Discovery and Joinability. 2024. URL: <https://doi.org/10.1109/ICDE60146.2024>.
- [8] NYC Open Data. 311 Service Requests from 2020 to Present. URL: <https://data.cityofnewyork.us/Social-Services/311-Service-Requests-from-2020-to-Present/erm2-nwe9>.